

PRESENTACIÓN DOCENTE


ESPECIALIZACIÓN EN

Inteligencia de Datos

para la Gestión Estratégica


Captura y análisis de la información de entrada

Clase 2 • Taller T8001 • Dr. Lautaro Di Bartolo • 28 de agosto, 18:00 a 21:00



01 • IDEA RECTORA

Entre el hecho y la fila siempre hay decisiones



Ninguna de las tres queda escrita en el archivo, y las tres condicionan el análisis posible.

Hoy diagnosticamos; recién después vamos a decidir

Clase 2 — hoy

- Observar sin modificar
- Documentar lo que se encuentra
- Formular hipótesis de captura

Clase 3 — la próxima

- Transformar una copia
- Comprobar cada resultado
- Registrar cada decisión

Una decisión de limpieza sin diagnóstico es una conjetura invisible.

EL CASO

12 hogares y 8 columnas, pero no 12 historias completas

La ficha del relevamiento

Productor: Desarrollo Social de un programa provincial

Período: marzo de 2025, una sola vez

Instrumento: encuesta en tablet, a domicilio

Unidad: el hogar visitado

Para qué: decidir dónde abrir un centro de salud.

id	localidad	fecha_visita	ingreso	cobertura_salud	satisfaccion
1	Ramallo	2025-03-14	185000	si	buena
3	Concepción	2025-03-15	(vacío)	NULL	NULL
5	ramallo	2025-03-16	120000	NULL	NULL
9	Ramallo	2025-03-18	999999	no	mala
14	Córdoba	2025-03-21	168000	no	regular

El hogar 9 termina en un espacio que no se dibuja, y faltan los id 6 y 12.

Nada de esto se corrige hoy: hoy solo se nombra.

¿Qué defectos se ven en estas cinco filas, y cuáles todavía no se ven?

AHORA, EN EL NOTEBOOK

Mirar antes de interpretar

texto crudo → DataFrame

¿Qué cambia pandas cuando abre el CSV?

► 1. El relevamiento de esta clase

pandas es la librería que abre archivos de datos. Un DataFrame es su tabla: filas y columnas, como una hoja de cálculo.

DE VUELTA A LA PRESENTACIÓN

Pandas hizo iguales dos ausencias que no eran iguales

(vacío) celda sin nada escrito

Es el hogar 3, en la columna ingreso.



NaN

así marca pandas una celda sin dato

«NULL» texto escrito

Alguien lo escribió. Son cobertura_salud y satisfaccion.



Leer también interpreta.

read_csv reconoce NULL como ausencia y lo convierte solo. Con esa conversión se pierde la única pista sobre qué pasó en la captura.

DE DÓNDE SALE UN DATO

Una fuente no es dónde está el servidor: es cuánto control tenemos

Interna y externa

Cambiar la captura


interna: negociando • externa: no

Saber qué significa

interna: a veces • externa: solo si hay diccionario

Sesgo principal

interna: del proceso • externa: del que publica



El dato llega desde sistemas que nacieron por separado y con otro propósito.

TIPOS DE FUENTE

Cada tipo de fuente deja algo afuera

De cada tipo alcanza con recordar qué deja afuera.

Transaccional

Solo existe lo que pasó por el sistema. Una venta en efectivo sin ticket no está.

Registro administrativo

Se actualiza cuando el ciudadano tiene un motivo.
Un domicilio puede tener diez años.

Sensor y telemetría

El sensor no sabe que se descalibró: sigue informando un número plausible.

Logs de sistemas

Miden interacción con la pantalla, no intención. Y se rotan: lo viejo se borra solo.

Formulario y encuesta

Contesta quien quiere, y contesta lo que le parece aceptable decir.

Web y datos abiertos

El organismo publica lo que decidió publicar, con el recorte que decidió.

Nuestro relevamiento es del quinto tipo, así que va a traer los problemas del quinto tipo.

ANTES DEL ARCHIVO

Unidad, población y período se fijan antes de abrir el archivo

¿Qué mide realmente?

No lo que dice el nombre de la columna: qué evento concreto produce una fila.

¿A quién no alcanza la fuente?

Toda población tiene una parte que la captura no llega a ver. Hay que nombrarla.

¿Hasta cuándo representa?

Un dato que se dejó de actualizar no es actual, aunque se baje hoy.

En este relevamiento

Unidad de observación: el hogar visitado, cuando un encuestador llegó y alguien le abrió.


Población: los hogares de Ramallo, Córdoba y Concepción. Queda afuera el hogar donde no había nadie a las tres de la tarde.

Período de referencia: marzo de 2025, una sola vez, y no se repite.

¿Quién queda afuera de una visita a domicilio a las tres de la tarde?

TRES PREGUNTAS DISTINTAS

Fuente, captura y transporte responden preguntas distintas



Una API puede transportar una encuesta. No por eso capturó las respuestas.

Una API expone y transporta; detrás todavía hay un instrumento

No es un mecanismo de captura


Una API da acceso al dato que ya capturó otro. No lo produjo: lo entrega, y le agrega defectos propios.

Dos advertencias

La misma dirección puede devolver algo distinto mañana; un archivo descargado queda fijo.

Puede truncar por un tope de registros, o devolver campos anidados.

Un tope de 1.000 registros sobre 12.000 hogares devuelve siempre los mil primeros, nunca mil al azar. Eso es un sesgo.



La API entrega lo que su dueño decidió exponer.

AHORA, EN EL NOTEBOOK

Cuatro maneras de traer un dato

`read_csv` • `read_excel` • `read_json` • `read_html`

¿Cuál sale mal sin dar ningún error?

► 2. Las cuatro formas de traer un dato

DE VUELTA A LA PRESENTACIÓN

Una lectura que no explota puede estar cien veces equivocada

El porcentaje de Ramallo

41,67 → 4167

pandas leyó la coma como separador de miles.

La suma de la columna Hogares

12 → 24

la fila TOTAL se sumó como una localidad más.

Ninguna de las dos lecturas dio error. dtypes no se quejó de nada.

Una tabla web es una presentación, no un conjunto de datos: los números vienen formateados para leer y no para calcular.

Después de leer: shape, head() y dtypes. Y además, contrastar contra lo que se esperaba.

DOS PROBLEMAS DISTINTOS

El error deforma valores; el sesgo deforma a quiénes vemos

La diferencia es la dirección

Error. Sin dirección. El grosero se ve en el archivo; el chico está en todas las filas y no se ve.


Sesgo. Sistemático. Empuja siempre para el mismo lado y no se cancela.

Con los diez ingresos declarados

205.150 de promedio. Un error de ± 2.000 por fila lo mueve menos de medio punto. Visitar solo Córdoba lo sube a 230.875, con los cuatro ingresos correctos.

Y un tercer caso: 999999 • NULL

no son fallas del mundo, son convenciones del instrumento.



ERROR


SESGO

El perfilado encuentra errores; el sesgo, no. El sesgo se detecta sabiendo cómo se capturó.

El error está en el valor; el sesgo está en quién quedó adentro.

HUELLAS DEL INSTRUMENTO

Si sabemos cómo se capturó, sabemos qué buscar



Cada instrumento deja una huella distinta, y esa huella se puede anticipar.

El error que sí se ve y detrás de cada uno, un sesgo que no

Formulario texto libre con variantes, fechas ambiguas

OCR O por 0, l por 1, acentos rotos

Sensor saltos imposibles, valor centinela (un número que significa «no sé»)

Logs zonas horarias mezcladas, rotación

Planilla celdas combinadas, colores como dato, totales en el medio

API tope de registros, campos anidados

Scraping números con símbolos, etiquetas de HTML coladas

Escribir en una línea cómo se capturó es el primer paso del diagnóstico.

DISEÑO PREVENTIVO

La calidad se diseña antes de preguntar

La tabla de captura se escribe antes del formulario, no después del problema.


variable	tipo	dominio	obligatoria	validación
personas	entero	1 a 20	sí	si vale 1, no puede haber menores
satisfaccion	opciones	mala, regular, buena	no	no preguntar si no usa el centro

Las reglas que faltaron en este relevamiento

Sin lista de opciones, localidad quedó con cinco valores para tres localidades.

Sin dominio explícito, el 999999 de ingreso entró sin que nada lo frenara.

Sin decidir cómo se guarda una respuesta múltiple, servicios quedó multivalor.



Lo que el formulario no valida se paga después.

¿Qué validación necesita mirar dos variables a la vez?

LAS TRES AUSENCIAS

No aplica, no contestó y no se preguntó no son el mismo vacío

-9 no aplica

La pregunta no correspondía a este hogar. No falta nada: la respuesta correcta es que no hay respuesta.

-8 no contestó

Correspondía y la persona no quiso contestar. Eso es un dato, y además es informativo.

-7 no se preguntó

Correspondía y falló el instrumento: se cortó la tablet, se saltó una hoja, el encuestador se olvidó.

Al declararlos como faltantes, los tres se vuelven el mismo.

Por eso el diccionario se escribe antes: después de esa línea, la distinción ya no existe.

AHORA, EN EL NOTEBOOK

Cuando todos contestan bien y la tabla sale mal

Cinco vecinos • una misma realidad • cinco formatos

¿El error está en la respuesta o en el instrumento?

► 3. El formulario sin diseño

DE VUELTA A LA PRESENTACIÓN

La validación tardía recupera formatos; no recupera significado

personas, como llegó

al convertir a número

qué pasó

«3»

3

recuperado

«tres»

NaN

se perdió

«3 personas»

NaN

se perdió

«-1»

-1

sobrevivió

«3»

3

recuperado

3 de 5

recuperados por la conversión.

Dos vecinos que contestaron bien quedaron fuera del cálculo, y los cuatro hogares de tres personas se partieron en tres grupos.

El -1 pasa la conversión.

Es un número válido. Solo lo detecta quien sabe qué rango es posible.

Dominio y validación pertenecen al diseño de la captura, no a la limpieza posterior.

02

Qué se puede calcular depende de qué representa


Pandas lo calcula sin protestar, y no significa nada.

Pausa de 10 minutos • volvemos 19:40

~~promedio(id) = 7,25~~

LOS CUATRO TIPOS

Cualitativa y cuantitativa son preguntas sobre el mundo



Una fecha entra por la rama cuantitativa y es discreta, porque se cuenta en días.

ESCALAS DE MEDICIÓN

Cada escala habilita operaciones y prohíbe otras

Son acumulativas

Nominal distingue. localidad


Ordinal además ordena. satisfaccion

Intervalo además mide distancia. fecha_visita

Razón además compara proporciones. personas

Subir un escalón nunca quita lo que permitía el anterior. El estadístico central cambia con la escala: moda, mediana y, en las dos últimas, media.

¿Por qué se pueden restar fechas, pero no dividir las?



Las cuatro escalas, sobre las variables del relevamiento.

El tipo de pandas no es la escala de medición

Lo que guardó la computadora

id int64

satisfaccion object, o sea texto

fecha_visita object, o sea texto

Lo que se tiene derecho a calcular

id etiqueta: no se analiza

satisfaccion ordinal: moda y mediana

fecha_visita intervalo: se resta, no se divide

satisfaccion y servicios comparten el tipo de pandas y no comparten la escala.

La escala no está en el archivo: alguien tiene que declararla, y ese lugar es el diccionario.

LA TRAMPA ORDINAL

Convertir una ordinal a números no crea distancias

Las ocho respuestas de satisfacción, con dos codificaciones distintas.

Codificación A

mala=1 · regular=2 · buena=3

1 1 2 2 2 3 3 3

promedio **2,125**

Codificación B

mala=1 · regular=2 · buena=10

1 1 2 2 2 10 10 10

promedio **4,75**

En las dos
mediana

regular

y la moda es un empate entre buena y regular, con tres cada una.

El promedio resume la codificación elegida, no una distancia medida.

Codificar supone que de mala a regular hay la misma distancia que de regular a buena. Nadie midió esas distancias: son etiquetas de un cuestionario.

¿Cuál de las dos codificaciones usarían para informar un resultado, y por qué?

TRAZABILIDAD

El dataset guarda valores; el diccionario guarda lo que significan

Las ocho columnas mínimas

variable el nombre exacto

descripcion qué mide, y de quién

tipo cualitativa o cuantitativa

escala cuál de las cuatro

unidad en qué está expresada

valores_admitidos el dominio

codigo_faltante cómo se marca una ausencia

origen de qué pregunta sale

Se escribe antes de capturar: después, el dominio hay que adivinarlo.



Sin diccionario, un dataset es una tabla que nadie puede auditar.

AHORA, EN EL NOTEBOOK

Pandas puede escribir solo la mitad del diccionario

tipo • cardinalidad • faltantes

¿Qué columnas del diccionario no pueden salir del archivo?

► 4. El diccionario de variables, a medias

DE VUELTA A LA PRESENTACIÓN

Automatizar el esqueleto no reemplaza documentar el significado

Lo que pandas escribe solo

tipo_pandas df.dtypes ← no es el tipo del apunte

valores_distintos df.nunique()

faltantes df.isna().sum()

Tres preguntas contestadas, todas sobre la forma del archivo.

Lo que tiene que aportar la fuente

descripcion

tipo cualitativa o cuantitativa

escala

unidad

valores_admitidos

codigo_faltante

origen

El espacio vacío de la derecha no es un error de la diapositiva: es conocimiento que el archivo no tiene.


03

Perfilar es inspeccionar en un orden estable

Todavía no limpiamos. Hoy solo miramos qué tiene la tabla.

LA RUTINA

Seis pasos convierten una tabla desconocida en preguntas concretas



La rutina indica dónde mirar, no qué decisión tomar.

- 1 TAMAÑO** `shape`
¿cuántas filas y columnas?
- 2 TIPOS** `dtypes`
¿pandas leyó bien cada columna?
- 3 RESUMEN** `describe()`
¿los rangos son posibles?
- 4 FALTANTES** `isna().sum()`
¿cuánto falta y dónde?
- 5 DUPLICADOS** `duplicated()` e `id.duplicated()`
¿filas repetidas? ¿id repetidos?
- 6 CARDINALIDAD** `nunique()`, `value_counts()`
¿cuántas categorías y cuáles?

Siempre en este orden, y siempre antes de tocar nada.

EL SEXTO PASO

La cardinalidad reconoce categorías, identificadores y problemas

Se compara la cantidad de valores distintos contra la cantidad de filas.

12 / 12

id

Tantos valores como filas: es un identificador. Y faltan el 6 y el 12.

3 y 2

satisfaccion • **cobertura_salud**

Pocos valores y muchas filas: son categorías.

5

localidad

Cinco valores distintos para tres localidades: es un defecto.

6

servicios

Seis valores distintos para cuatro servicios: es una columna multivalor.

Un número intermedio y raro casi siempre es un problema.

localidad y servicios se diagnostican hoy y no se tocan: se arreglan en la clase 3.

AHORA, EN EL NOTEBOOK

Los seis pasos, y un error que queremos ver

El bloque rojo
no es un problema: es evidencia

¿Qué dice un TypeError sobre la escala de la variable?

► 5. Los seis pasos del perfilado

DE VUELTA A LA PRESENTACIÓN

El perfilado encuentra anomalías; la escala decide qué significan

277.409 → 205.150

El centinela inflaba el promedio un 35% sobre el promedio real. El perfilado lo mostró, y solo un diccionario podría decir que 999999 no es un ingreso. Este relevamiento no lo tiene.

5 etiquetas, 3 localidades

value_counts separó Ramallo, ramallo y Ramallo con espacio final. Contar categorías no alcanza: hay que mirar los bordes del texto.

TypeError en satisfaccion

Pandas se negó a promediar texto. No impediría promediar la misma variable codificada, y ahí el error deja de ser visible.

Ninguna salida automática reemplaza el criterio ni el diccionario.

LA HERRAMIENTA NUEVA

Un filtro de verdaderos y falsos formula preguntas sobre filas

Entran 12 filas, salen 12 booleanos


Una comparación devuelve una columna del mismo largo que la tabla, con True donde se cumple y False donde no.

Los nombres eligen columnas; los booleanos eligen filas.

Booleano quiere decir de dos valores: verdadero o falso.

```
comparacion = df["personas"] > 4  
df[comparacion]
```

Devuelve tres hogares: los id 2, 7 y 11.



El filtro decide qué filas pasan; las columnas quedan todas.

AHORA, EN EL NOTEBOOK

¿Por qué faltan siempre las dos juntas?

4 en cobertura_salud • 4 en satisfaccion

¿Son las mismas cuatro filas, o son cuatro y cuatro distintas?

► 6. El caso de los ocho NULL

CIERRE DE LA CLASE

Ocho NULL cuentan una historia que el archivo no puede cerrar

LO QUE SABEMOS

- Faltan las dos, en las mismas cuatro filas. 4 de 4
- No se concentran en una localidad: dos en Ramallo, uno en Córdoba, uno en Concepción.
- No se concentran en un tramo: del 15 al 20 de marzo, dentro del 14 al 21.
- No son celdas vacías: son el código NULL, que escribió algún programa.

LO QUE NO PODEMOS ELEGIR

- Un salto condicional, por una pregunta previa que no está en el archivo.
- Un módulo opcional que el encuestador podía omitir.
- Un solo encuestador, o una sola tablet. Ninguna columna lo identifica.
- Un artefacto de la exportación: NULL es la firma de un volcado de base.

Con cuatro casos, ni la localidad ni la fecha quedan descartadas: solo no saltan a la vista.

Primero documentar y diagnosticar; después decidir.

Los faltantes no son ruido que hay que sacar: son un dato sobre el instrumento de captura, y a veces son el único que queda.