

PRESENTACIÓN DOCENTE


ESPECIALIZACIÓN EN

Inteligencia de Datos

para la Gestión Estratégica

Limpieza, codificación, normalización y gráficos

Clase 3 • Taller T8001 • Dr. Lautaro Di Bartolo • 29 de agosto, 9:00 a 12:00



01 • PUNTO DE PARTIDA

La clase 2 dejó problemas escritos; hoy hay que decidir

Siete formas para tres localidades

Espacio final, minúscula, mayúsculas y un acento que falta.

Un centinela y un cero

999999 no es un ingreso. El 0 del hogar 38 sí lo es.

Diez filas con NULL

cobertura_salud y satisfaccion faltan siempre en las mismas diez filas.

Fechas como texto

Treinta y seis en ISO y cuatro en dd/mm/aaaa.

Una celda con varios valores

servicios guarda hasta cuatro servicios por celda.

Filas repetidas

Un duplicado exacto y un id que aparece dos veces con otro contenido.

¿Qué hacemos con cada uno?

CRITERIO DE EVALUACIÓN

Casi ninguna decisión de limpieza tiene una única respuesta correcta

Borrar / imputar

Borrar pierde las otras siete columnas de esa fila.
Imputar agrega un valor que nadie midió.

Conservar / revisar el extremo

Conservar puede dejar entrar un error de carga.
Sacarlo puede borrar el caso más informativo.

Elegir / descartar el conflicto

Elegir una fila supone un criterio sin evidencia.
Descartar las dos pierde un hogar entero.

No se evalúa la operación: se evalúa la justificación.

Para cada decisión hay que poder escribir qué se hizo, sobre cuántas filas, qué supuesto contiene y qué se pierde.

¿Qué tendría que quedar escrito para que otra persona pueda defender la decisión?

Las mismas operaciones, en otro orden, producen otra tabla

Un caso concreto

Diez filas dicen NULL en dos columnas, y hay una fila repetida entera.

$$10 / 40 = 25\%$$


si se informa antes de sacar el duplicado

$$10 / 37 = 27\%$$

sobre las filas que quedan al final

Los dos números son ciertos y no dicen lo mismo.

Siempre declarar sobre qué versión de la tabla se calculó un resultado.




25% y 27% son el mismo hueco contado sobre bases distintas.

REPRODUCIBILIDAD

Un pipeline empieza en el crudo y se reconstruye de punta a punta

Un pipeline es la secuencia completa de operaciones, escrita en un solo lugar y en orden.

**Regla 1**

Cada ejecución arranca leyendo el crudo. Nunca una tabla intermedia que quedó en memoria de una corrida anterior.

Regla 2

Cada paso deja el anterior intacto. Si el paso 3 se equivocó, se corrige el 3 y se corre todo de nuevo, sin deshacer nada a mano.

Si no se puede borrar todo y reconstruirlo ejecutando de arriba hacia abajo, no hay pipeline.

Hay una tabla que nadie sabe cómo se armó. Una corrección manual que no se puede repetir no pertenece al pipeline.

AHORA, EN EL NOTEBOOK

El orden se ve antes de limpiar

7 formas → 4 formas

¿Qué duplicado podría aparecer recién después de unificar el texto?

- ▶ 1. El relevamiento completo, y el orden

DE VUELTA A LA PRESENTACIÓN

Unificar primero evita que una diferencia de escritura oculte un duplicado

Caso hipotético: este par no está en el relevamiento, y por eso hay que saber que puede estar.

COMO LLEGÓ

id	localidad	personas	ingreso
17	Ramallo	4	198000
17	ramallo	4	198000

drop_duplicates() no encuentra nada.

Para la máquina son dos textos distintos.

CON EL TEXTO UNIFICADO

id	localidad	personas	ingreso
17	ramallo	4	198000
17	ramallo	4	198000

Con el texto unificado, sí lo encuentra.

Las dos filas ya son idénticas en todas sus columnas.

El texto se unifica antes de buscar duplicados, no después. Si no, los aproximados sobreviven.

DUPLICADOS

El duplicado exacto se detecta; el aproximado se investiga

Dos problemas distintos

Duplicado exacto


Una fila idéntica a otra en todas sus columnas. Se saca con `drop_duplicates()`, y casi siempre es un error de carga.

Duplicado aproximado

La misma observación cargada dos veces con una diferencia mínima. No lo encuentra ninguna función.

Consecuencia: texto primero, duplicados después.

¿Qué diferencia mínima impediría que `drop_duplicates()` encuentre el caso?



El duplicado exacto se cae solo. El aproximado hay que ir a buscarlo.

ANTES DE BORRAR

Una fila repetida puede ser legítima o puede ser un conflicto

Si el diccionario dice: una fila por hogar

- Una fila repetida es un error de carga
- El id identifica al hogar, y hay uno solo por hogar
- Sacar la repetida no pierde nada

Si el diccionario dice: una fila por visita

- Dos filas iguales son dos observaciones
- El relevamiento no guardó hora ni encuestador
- Sacar una pierde información real

Y hay un tercer caso, que no se resuelve borrando: mismo id + contenido distinto = conflicto.

La unidad de observación decide si la repetición sobra. La decide el diccionario, no el archivo.

EL CASO

El id 41 obliga a elegir, y las tres salidas cuestan algo

id	localidad	personas	ingreso	satisfaccion
41	Córdoba	3	213000	regular
41	Córdoba	5	254000	buena

Dos filas dicen ser el mismo hogar y no coinciden.

O una de las dos está mal, o son dos hogares a los que se les asignó el mismo número.

Volver a la fuente

Es la única que resuelve de verdad.
Costo: hace falta acceso a quien capturó.

Conservar una, con criterio

Por ejemplo la última cargada.
Costo: el criterio no tiene evidencia detrás.

Descartar las dos

Nadie sabe cuál vale.
Costo: se pierde un hogar entero.

La decisión de este taller: descartar las dos y dejarlo escrito. Son dos filas, pero un solo hogar.

AHORA, EN EL NOTEBOOK

¿Cuántos hogares quedan en pie?

40 → 39 → ?

¿Qué información se pierde en cada opción?

► 2. Duplicados y conflicto

DE VUELTA A LA PRESENTACIÓN

Cuarenta filas terminan en treinta y siete hogares por dos razones distintas

40

filas recibidas en el archivo crudo.

→

39

sin el duplicado exacto: la última fila repetía entera la anterior.

→

37

sin las dos filas en conflicto del id 41.

-2 filas en conflicto = -1 hogar. Las dos filas representaban un solo hogar del relevamiento.

Los tres conteos documentan decisiones diferentes y no son intercambiables.

TRES COSAS DISTINTAS

Cero, vacío y centinela producen números parecidos y significados opuestos

En la columna ingreso

Hogar 3 • vacío

Nadie escribió nada. Es una ausencia, y se mantiene así.


Hogar 38 • 0

Es un ingreso declarado, y vale cero. No falta: es un dato.

Hogar 9 • 999999

Una ausencia disfrazada de dato: alguien eligió ese número para decir «no sé». Se convierte en ausencia.

El primer paso no es decidir qué hacer: es averiguar cuáles son faltantes.



Tres celdas que parecen lo mismo y significan tres cosas distintas.

TRES ESTRATEGIAS

Borrar, imputar o conservar: las tres cambian lo que podemos afirmar

Borrar la fila entera

Es honesto y no inventa nada. Pierde las otras siete columnas de esa fila, que estaban completas. Y si los faltantes no están repartidos al azar, sesga la muestra.

Imputar el hueco

Conserva la fila y agrega un dato que nadie midió. La variabilidad de la columna queda más chica de lo que es, porque los valores imputados no varían.

Conservar la ausencia

No inventa ni descarta. Limita la base analítica: todo cálculo sobre esa columna se hace sobre menos filas, y hay que informarlo.

Si se imputa, dejar una columna que diga cuáles se imputaron. Si no, nadie puede distinguir un dato medido de uno inventado.

RUBIN, 1976

MCAR, MAR y MNAR son hipótesis sobre la causa, no etiquetas automáticas

De qué depende la ausencia

MCAR al azar del todo

No depende de nada. Es el único caso en el que borrar no sesga.


MAR al azar condicionado

Depende de otra columna que sí está en la tabla. Se puede imputar por ella.

MNAR no al azar

Depende del valor que falta. Cualquier cosa que se haga sesga, y ninguna técnica lo arregla.

¿Cuál de los tres no se puede confirmar mirando la tabla?



De qué depende la ausencia decide qué se puede hacer con ella.

EL CASO HEREDADO

Con los diez hogares sin respuesta, no decidir puede ser la decisión correcta

Si fue un salto condicional

Esas dos preguntas no correspondían a esos hogares. No son faltantes: son «no aplica». Borrar esas diez filas sería borrar diez hogares válidos que no usan el centro de salud.

Si fue un fallo del instrumento

Sí son faltantes, y entran en la discusión de borrar, imputar o conservar de la diapositiva 14.

Las dos lecturas llevan a decisiones opuestas, y son diez hogares de treinta y siete.

La tercera vía: no borrar, no imputar, informar $n = 27$ hogares.

Las dos columnas se conservan con la ausencia marcada. Todo análisis que las use informa $n = 27$, no 37.

Es la única salida que no inventa un dato ni descarta uno bueno.

Cuando no se puede decidir, la opción correcta es no decidir y decirlo. Lo que no se puede es decidir en silencio.

AHORA, EN EL NOTEBOOK

Un valor infla el promedio y otro lo baja con razón

vacío • 0 • 999999

¿Cuál de los tres se toca?

► 3. Las tres formas de que no haya un dato

DE VUELTA A LA PRESENTACIÓN

El centinela se corrige; el cero se conserva; el vacío sigue declarado

se corrige

999999 del hogar 9. Se convierte en ausencia antes de calcular, porque no es un ingreso.

se conserva

0 del hogar 38. Es un ingreso declarado, y baja el promedio como corresponde.

sigue declarado

vacío del hogar 3. No se imputa: queda como ausencia y se informa.

Después de corregir el centinela: **35 ingresos declarados y promedio 203.471, contra 225.597 con el centinela adentro.**

El significado manda sobre la forma.

No se tratan los valores por su apariencia ni por incomodidad estadística.

02

Lo mecánico y lo semántico se separan

Texto, fechas y extremos: hasta dónde llega la herramienta y dónde empieza la decisión.


Pausa de 10 minutos • volvemos 10:40

Mecánico: bordes, mayúsculas, acentos

Semántico: equivalencias, formatos ambiguos

LIMPIEZA DE TEXTO

Tres pasos mecánicos reducen siete escrituras a tres localidades



Cada paso junta lo que estaba separado por una diferencia de escritura.

Y queda un cuarto paso que ninguna función hace.

Decidir si «Concep.» y «Concepción» son la misma localidad es semántico.



Las cuatro formas que sobran

«Ramallo » con un espacio final que no se dibuja · 1 fila

«ramallo» en minúscula · 2 filas

«CONCEPCIÓN» en mayúsculas · 2 filas

«Cordoba» sin acento · 1 fila

Sobre 37 filas: ramallo 15 · cordoba 11 · concepcion 11

Los tres pasos son mecánicos: se aplican sin mirar el contenido.

FECHAS

Una conversión que falla señala el problema; una que adivina puede ocultarlo

Tres caminos

Sin decir nada ValueError

Pandas se planta y dice qué valor no encajó. Buena noticia.


errors="coerce" 33 de 37

Convierte las que entiende y deja las otras cuatro sin convertir. También buena.

format="mixed" 37 de 37, sin un error

Adivina el formato de cada fecha. Donde hay dos lecturas elige mes/día, y corrompe dos en silencio.

¿Por qué 02/04/2025 no se resuelve mirando solo el texto?



rango que da: 4 de febrero → 4 de julio

rango real: 14 de marzo → 9 de abril

La conversión parcial señala exactamente qué filas revisar.

AHORA, EN EL NOTEBOOK

Primero queremos que la fecha falle

El bloque rojo
protege el dato

¿Cuál de las dos salidas es peor, la que falla o la que convierte todo?

► 4. Texto y fechas

DE VUELTA A LA PRESENTACIÓN

El resultado correcto incluye 37 fechas y una comprobación de rango

37 / 37

convertidas por los dos pasos: primero ISO, después las cuatro restantes con su formato declarado.

14 mar → 9 abr

el rango que tiene que ser, y el que hay que mirar después de convertir.

26 días

duró el relevamiento. Mirar el rango es necesario, y no alcanza como prueba.

Cuatro visitas llegaron en dd/mm/aaaa y hubo que declararles el formato aparte:

• 25/03/2025 • 28/03/2025 • 02/04/2025 ← mixed la rompía • 07/04/2025 ← mixed la rompía

Convertir y comprobar son dos pasos, no uno.

Y el rango no alcanza como prueba: 03/04/2025 se convertiría en 4 de marzo, caería dentro del período y nadie lo notaría.

VALORES EXTREMOS

Un extremo es un candidato para investigar, no una orden de borrado

Tres casos distintos

999999 • hogar 9

No es un extremo: es un centinela, y ya se resolvió. Se saca antes, porque si no domina el cálculo.


620.000 • hogar 39

Tres veces el promedio. Puede ser un cero de más, o el hogar de mayor ingreso.

12 personas • hogar 39

El mismo hogar. Eso hace la fila más creíble, no menos.

Un extremo no se borra: se investiga. Y si no se puede, se anota.



$620.000 \div 12 \text{ personas} = 51.667 \text{ por persona}$

que es exactamente la mediana del relevamiento. La fila se sostiene.

La distancia al resto no dice si el valor es falso.

DOS DETECTORES

IQR y z-score discrepan porque miran la distribución de maneras distintas

valor de ingreso	hogar	IQR	z-score
0	38	lo marca	lo marca, $z = -2,33$
310.000	7	lo marca	no lo marca, $z = 1,22$
620.000	39	lo marca	lo marca, $z = 4,77$

IQR: el ancho de la mitad del medio, entre el primer y el tercer cuartil. · Z-score: a cuántos desvíos del promedio está cada valor.

Sobre los 35 ingresos declarados: $Q1 = 173.500$ · $Q3 = 219.500$ · $IQR = 46.000$ · límite 288.500.

Promedio 203.471 y desvío 87.360: el z-score usa los dos, y los dos se corren con un valor grande.

Si se saca el 620.000, el 310.000 pasa a $z = 2,40$ y queda marcado. Un extremo puede tapar a otro.

El que discrepa

310.000, del hogar 7, que ya aparecía en la clase 2.

El IQR no usa el promedio: mira en qué puesto quedó cada valor. Si el 620.000 fuera 5.000.000, los dos límites quedarían iguales.

En personas no hay discrepancia: los dos métodos marcan el 12 y nada más.

umbral IQR 1,5 · umbral z 2 (el habitual es 3; acá 2 para que discrepen)

Los dos umbrales son convenciones. Los métodos proponen candidatos; quien decide es una persona.

«Normalizar» puede significar tres operaciones diferentes

Conviene nombrarlas

Codificar

Convertir categorías en números. Cambia el tipo del dato.


Escalar

Llevar variables numéricas a un rango comparable. Cambia la magnitud.

Normalizar la estructura

Cambiar la forma de la tabla, de ancha a larga o al revés. No toca ningún valor.

Las tres se hacen al final, cuando el dato ya está limpio.



Tres operaciones distintas con el mismo nombre.

CODIFICACIÓN

Codificar respeta la escala o inventa una estructura que no existe

satisfacción es ordinal

- Una sola columna: mala 1, regular 2, buena 3
- Sirve para ordenar y para la mediana, que da 2
- Sobre 27 respuestas: con 1, 2 y 10 el promedio salta de 2,07 a 4,41 y la mediana no cambia

localidad es nominal

- Una columna por categoría, con 1 y 0
- Con el texto limpio salen tres columnas
- Con el texto sucio salen siete, cuatro de ellas casi vacías

Codificar supone que de mala a regular hay la misma distancia que de regular a buena, y la escala no dice eso.

Codificar es lo último: si se codifica antes de unificar el texto, el error se multiplica.

¿Qué pasa con las tres columnas de localidad si mañana aparece una cuarta?

Una celda multivalor puede abrirse a lo largo o a lo ancho


Dos salidas correctas

A lo largo

Una fila por hogar y por servicio: el hogar 1 ocupa tres filas. Respetar la regla de un valor por celda.

A lo ancho

Una columna por servicio, con 1 y 0. Es la forma que se calcula.



El defecto plantado

Casi todas las filas separan con punto y coma; dos usan coma.

`str.get_dummies(sep=";")` → 6 columnas

sin error, cuando hay cuatro servicios.

Con la coma reemplazada antes de partir: **luz 35 • agua 31 • gas 17 • cloacas 5**

A lo largo se guarda; a lo ancho se calcula.

ESCALADO

Min-max acota; z-score muestra distancia al centro

Sobre la columna personas

personas va de 1 a 12 e ingreso va de 0 a 620.000: no se pueden comparar sin llevarlas a un rango común.


Min-max el mínimo va a 0 y el máximo a 1

El 3, que es un tamaño de hogar corriente, va a 0,18. Ese 0,18 avisa que el 12 está estirando la escala hacia arriba.

Z-score el promedio va a 0

El 3 va a -0,37 y el 12 va a 3,92. No queda acotado, y acá eso es una ventaja.

Ninguno cambia la distribución ni corrige un extremo: lo mueve de lugar.



personas

min-max

z-score

3

0,18

-0,37

12

1,00

3,92

Dos maneras de hacer comparables dos variables en rangos distintos.

AHORA, EN EL NOTEBOOK

Dos métodos pueden discrepar y los dos estar bien calculados


0 • 310.000 • 620.000

¿Qué hacemos cuando los dos métodos no coinciden?

► 5. Extremos, codificación y escalado

DE VUELTA A LA PRESENTACIÓN

El cálculo termina donde empieza la justificación



Conservar 0, 310.000 y 620.000 es una decisión argumentada, no una omisión.

Lo que se informa no es el resultado solo: es qué método se usó y por qué.

03 • REPRESENTACIONES GRÁFICAS

La escala de medición ayuda a elegir el gráfico

No es una cuestión de gusto: la escala decide qué gráfico tiene sentido.


SI LA VARIABLE ES	EL GRÁFICO ES	Y EL OTRO ESTÁ MAL PORQUE
Nominal	 Barras	Un histograma supone un orden que no existe
Ordinal	 Barras en el orden de la escala	Ordenar por frecuencia borra el orden
Discreta, pocos valores	 Barras, una por valor	Un histograma inventa intervalos
Continua	 Histograma o caja	Barras con 35 valores no se leen
Dos numéricas	 Dispersión	Dos histogramas no muestran la relación

La ordinal es la que más se incumple: sobre 27 respuestas, en el orden de la escala son mala 7, regular 11 y buena 9.

DISTORSIÓN


Un eje recortado, una escala inadecuada o una selección silenciosa engañan

El eje que no arranca en cero




Sobre 37 filas los conteos son 15, 11 y 11: el más alto es 1,36 veces el más bajo. Con el eje desde 10, las barras miden 5, 1 y 1. La regla es de las barras: en una línea o una nube, cortar el eje es legítimo.

La ordinal ordenada por frecuencia



Por frecuencia sale regular, buena, mala. El pico en el medio desaparece, y con él la única lectura que la ordinal permitía.

El extremo que se saca sin avisar



La correlación r va de -1 a 1 . Sin el hogar 39 la nube queda más prolija y r baja de 0,79 a 0,56. Eso no es limpiar: es elegir el resultado.

Un gráfico puede contener números correctos y sugerir una conclusión falsa. ¿Qué decisión quedó oculta?

AHORA, EN EL NOTEBOOK

Cuatro gráficos, cuatro preguntas distintas

localidad • satisfaccion • ingreso • personas × ingreso

¿Qué cambia con el eje recortado: el dato, el gráfico o la impresión?

► 6. Los cuatro gráficos

CIERRE DE LA CLASE

El resultado final es el dataset más el registro de decisiones



0,79 → 0,56 sin el hogar 39.

Por puestos pasa de 0,58 a 0,54: lo que el hogar 39 infla es la estimación, no la asociación.

Antes de crearle a un coeficiente, mirá la nube de puntos.

EL REGISTRO MÍNIMO DE CADA DECISIÓN

operación qué se hizo, con qué función y con qué argumento

base sobre cuántas filas: 40, 39, 37, 35 o 27

supuesto qué se dio por cierto sin poder comprobarlo

pérdida qué información deja de estar disponible

comprobación qué se miró después para saber que salió bien

Limpiar es poder reconstruir y explicar.

37 hogares · 35 ingresos · 27 respuestas de satisfacción