

ESPECIALIZACIÓN EN **INTELIGENCIA DE DATOS** para la Gestión Estratégica

TRABAJO FINAL

Clase 4 · Taller T8001 — Pre-procesado de datos

Docente: Dr. Lautaro Di Bartolo

Asignatura: T8001 — Pre-procesado de datos

Cohorte o comisión: Cohorte 2026




Figura 1. El resultado no es el dataset limpio: es el dataset limpio más el registro de cómo se llegó a él.

1. LA CONSIGNA

Elegí un dataset real y sucio, y entregá su pre-procesado completo y documentado: de dónde salió el dato, qué problemas tiene, qué decidiste hacer con cada uno y por qué, y el dataset limpio con sus gráficos.

Es todo lo que practicaste en las clases 1 a 3, aplicado a un dato que nadie preparó para vos.

La entrega es opcional y es la recomendada: es la única del taller, y la única forma de recibir una devolución personal. Lo que se evalúa no es la limpieza: es la justificación de cada decisión.

La herramienta la elegís vos. Recomendamos un notebook de Google Colab, porque es la herramienta del taller y porque el código que limpia es, al mismo tiempo, el registro de la limpieza. También se puede hacer con Excel, con otra planilla o con otro lenguaje: lo que se evalúa es el criterio sobre los datos, y el criterio no depende de la herramienta. Lo que sí cambia con la herramienta es cómo demostrás que tu trabajo es reproducible, y eso está en la sección 3.

Cuánto tiempo lleva. Entre dos y tres horas si usás uno de los datasets provistos, algo más si salís a buscar el tuyo. El tiempo no se va en limpiar: se va en **escribir en castellano** el diccionario, el informe de problemas y las justificaciones, que es lo que se evalúa. Un reparto que funciona: una hora para la ficha, el diccionario y el diagnóstico; una hora para limpiar y escribir cada decisión; media hora para los gráficos, exportar y revisar contra la lista de la sección 6. Si podés, dejá la revisión final para el día siguiente: releer el mismo día es la peor forma de encontrar lo que falta.

2. QUÉ ENTREGÁS

Cinco piezas. Con un notebook, las cinco viven adentro del notebook. Con otra herramienta, son un documento más los archivos que se indican en cada caso.

1. **Caracterización de la fuente.** Quién publica el dato, con qué mecanismo de captura se generó cada fila, qué sesgo esperás por ese mecanismo, qué representa una fila, licencia y frecuencia de actualización. Es la ficha de la clase 2, y **seis renglones alcanzan**. Lo que el portal no informe, va como "no informado": señalarlo también es un hallazgo.
2. **Diccionario de variables, con al menos cinco variables documentadas: las que use tu análisis.** Para cada una, su escala de medición, una descripción que agregue información y sus valores admitidos. Son las columnas de la clase 2, sección 6.5. Si tu dataset tiene veinte columnas, no hace falta documentarlas todas: elegí con cuáles vas a trabajar y decilo.
3. **La limpieza y la codificación.** Los pasos que van del crudo al limpio, en el orden de la clase 3, con el dato crudo intacto y en la forma reproducible que pide la sección 3.
4. **El dataset limpio exportado, y al menos dos gráficos**, cada uno con su lectura escrita en dos o tres líneas. Un gráfico sin lectura no cuenta.
5. **Informe de problemas y decisiones.** Una fila por problema: qué está mal **con el número**, en cuál de las siete dimensiones de calidad cae, qué decidiste y **por qué**. Se esperan **al menos cuatro problemas**, y al menos dos con la justificación completa: qué alternativa había y qué se pierde con tu decisión. Se escribe mientras limpiás y se presenta al final: es el corazón del trabajo.

Qué NO se evalúa: la elegancia del código, y el código mismo. No hace falta saber Python de memoria, y un trabajo entero hecho en una planilla puede estar perfecto. Se evalúa qué viste, qué decidiste y por qué.

3. REPRODUCIBLE EN CUALQUIER HERRAMIENTA

Reproducible quiere decir que otra persona, con el dato crudo y con tu registro, puede rehacer el proceso y llegar exactamente al mismo archivo limpio.

Esa es la regla, y vale igual para todas las herramientas. Lo que cambia es cómo se cumple:

- **Con un notebook.** El notebook corre de punta a punta, en orden y sin intervención manual: descarga el crudo desde su URL, lo limpia y exporta el resultado. La prueba es Entorno de ejecución → Reiniciar y ejecutar todo sin que falle ninguna celda. El registro es el propio notebook.
- **Con Excel u otra planilla.** El crudo se guarda aparte y no se abre nunca para editar: se importa como enseña la clase 1, sección 5.3, con Datos → Obtener datos → Desde texto/CSV, fijando el tipo de las columnas que son códigos. El trabajo se hace sobre una copia, y el registro es una **lista numerada de todos los pasos manuales**, en orden, con el detalle suficiente para que otra persona los repita: qué columna, qué operación, qué valores. Un paso que no está en la lista es un paso que no existió.
- **Con otro lenguaje.** El script que va del crudo al limpio, ejecutable de una sola vez, más las instrucciones para correrlo.

En los tres casos vale la regla de las clases 1 a 3: **el archivo original no se modifica nunca**. Se descarga una vez, se guarda aparte, y todo lo que produzcas sale de una copia.

4. EL DATASET

4.1 Los tres provistos

Si no querés buscar un dataset, usá uno de estos tres. Son datos reales de portales públicos, verificados en agosto de 2026 y guardados en el repositorio del taller para que no dependas de que el portal esté en línea. Están ordenados de más fácil a más difícil, y cualquiera de los tres alcanza para el trabajo completo.

Dataset	Origen	Filas x Cols	Se lee con
Participación Ciudadana	Sec. de Comunicación, CABA	2 182 x 15	por defecto
Calidad de aire 2017	Agencia de Protección Ambiental, CABA	8 652 x 11	sep=";"
BAFICI. Films 2015	Min. de Cultura, CABA	2 131 x 15	sep=";", encoding="latin-1"

Se descargan de estas direcciones, que sirven igual desde un navegador que desde un notebook:

```
https://raw.githubusercontent.com/lautarodibartolo-ae/t8001-pre-procesado-de-datos/main/clase-4-trabajo-final/datos/participacion_ciudadana.csv
https://raw.githubusercontent.com/lautarodibartolo-ae/t8001-pre-procesado-de-datos/main/clase-4-trabajo-final/datos/calidad_aire_2017.csv
https://raw.githubusercontent.com/lautarodibartolo-ae/t8001-pre-procesado-de-datos/main/clase-4-trabajo-final/datos/bafici_films_2015.csv
```

El archivo datos/README.md del repositorio lista los problemas ya conocidos de cada uno. Podés leerlo, y hay una condición: **al menos dos de los problemas de tu informe tienen que ser tuyos**, es decir, no figurar en esa lista. Los tres datasets tienen bastante más de lo que la lista anuncia. Copiar la lista no es diagnosticar: es transcribir.

La ficha de cada dataset, con su licencia y su frecuencia declarada, vive en [Buenos Aires Data](#): buscarla es parte de la caracterización de la fuente.

4.2 Si preferís elegir el tuyo

Mejor todavía: el trabajo sale más honesto sobre un dato que te importa. Requisitos, y conviene comprobarlos antes de comprometerte:

Requisito	Por qué
Al menos 500 filas	Con menos, los gráficos y los estadísticos no dicen nada.
Entre 5 y 15 columnas	Con menos, el diccionario queda pobre. Con más, se vuelve la sección más larga del trabajo.
Al menos una variable de razón o intervalo	El histograma, los cuartiles y el escalado la necesitan.
Que NO esté limpio	Sin problemas no hay decisiones que justificar, y ahí está el corazón del trabajo.
Descarga directa, sin clave ni registro	El proceso tiene que poder rehacerse.
Formato CSV, XLSX o JSON	Son los que cubrimos en el taller.
No más de 200 000 filas ni 50 MB	Con más, Colab y Excel empiezan a sufrir. Si es más grande, quedate con un recorte documentado, por ejemplo un año.




Figura 2. Elegir bien el dataset evita que un problema de alcance arruine todo el trabajo.

La prueba de los tres minutos: bajalo y hacete estas cuatro preguntas. ¿Hay faltantes en varias columnas? ¿Alguna columna que debería ser número quedó como texto? ¿Alguna categoría está escrita de más de una forma? ¿Hay filas duplicadas? Con dos que den "sí", el dataset sirve. Y ojo con la trampa opuesta: si el conteo de faltantes da todo cero, puede significar que están disfrazados de "S/D", "-" o 999, como en la clase 2.

Dónde buscar: [Buenos Aires Data](#), el [catálogo de la Provincia de Buenos Aires](#) y el [Portal Nacional de Datos Públicos](#). Si a los 40 minutos seguís mirando catálogos, agarrá uno de los tres provistos y empezá.

5. QUÉ SE EVALÚA, Y LA GUÍA DE PASOS

No hay nota. La devolución es personal y mira una sola cosa: **el criterio sobre los datos**. Lo que más pesa en ella es el diagnóstico y la justificación de las decisiones, que no se resuelven con código: se resuelven escribiendo por qué hiciste lo que hiciste.

Esta lista es las dos cosas a la vez: los pasos que casi seguro tiene tu trabajo, en el orden en que conviene hacerlos, y qué se mira de cada uno en la devolución.

1. **Elegí el dataset y escribí la ficha de la fuente.** Lo que más se mira es el mecanismo de captura y el sesgo que produce, porque anticipa qué errores buscar: es la tesis de la clase 2.
2. **Mirá el archivo antes de que la herramienta lo interprete.** Separador, decimal, encoding y basura arriba del encabezado, con la lista de verificación de la clase 1, sección 6.5. Todo lo que declares al leer es un supuesto tuyo, y va anotado.
3. **Corré el perfilado completo antes de tocar nada:** tamaño, tipos, resumen, faltantes, duplicados y cardinalidad, en el orden de la clase 2, sección 7.1. De acá sale la mayoría de los problemas del informe.
4. **Escribí el diccionario de las columnas que vas a usar.** La columna que más se equivoca es la escala: un código guardado como número no es una cantidad. Una descripción que repite el nombre de la columna no agrega nada.
5. **Anotá cada problema con su número y su dimensión.** "Hay faltantes" no es un problema detectado; "la columna `te1` tiene 922 valores sin dato sobre 2 840, el 32%" sí. Buscá también los faltantes disfrazados, "S/D", "-", "999": son lo que más se pasa por alto. Un problema reportado que no existe le quita credibilidad al resto del informe.
6. **Limpiá en el orden de la clase 3, sección 2.1:** texto, duplicados, tipos y fechas, faltantes, y extremos al final. Después de cada paso mirá el resultado, y escribí la decisión en el momento, no al final. Una justificación completa dice qué alternativas había, por qué elegiste esa y **qué se pierde**: toda limpieza pierde algo, y reconocerlo vale más que esconderlo. "No hice nada" es una decisión válida si decís por qué.
7. **Codificá una variable según su escala.** Una ordinal con su orden justificado, o una nominal con una columna por categoría, diciendo por qué no lleva números del 1 al 3. Confundir esas dos es el error más caro del diccionario.
8. **Hacé los dos gráficos y escribiles su lectura.** Cada uno según la escala de su variable, con la tabla de la clase 3, sección 7.1, y la ordinal siempre en el orden de la escala. La lectura dice qué **implica** lo que se ve, no qué se ve.
9. **Exportá y comprobá que otra persona puede rehacer todo.** Es la prueba de la sección 3, y es lo primero que se revisa.

La diferencia entre una justificación que vale poco y una que vale mucho:

- Vale poco: *"Se eliminaron los valores nulos de la columna edad."*
- Vale mucho: *"La columna edad tiene 312 faltantes sobre 4 500, el 7%. No los imputé con la mediana porque se concentran en los registros de 2019, cuando el formulario todavía no pedía el dato: imputar inventaría una distribución que no observamos. Los dejé como faltantes y los excluí solo del histograma."*

La segunda dice qué vio, qué descartó y por qué. Esa es la respuesta que se busca.




Figura 3. Un dataset puede estar completo y ser inconsistente, o ser exacto y estar desactualizado.

6. LISTA DE VERIFICACIÓN ANTES DE ENTREGAR

1. **Rehacé el proceso desde cero.** Con notebook: reiniciar y ejecutar todo, sin errores. Con planilla: seguí tu propia lista de pasos sobre una copia fresca del crudo y comprobá que llegás al mismo archivo.
2. **El crudo está intacto** y guardado aparte de todo lo que produjiste.
3. **El diccionario tiene al menos cinco variables documentadas**, ninguna quedó sin escala, y los identificadores figuran como identificadores.
4. **Hay al menos cuatro problemas, cada uno con su número**, su dimensión, su decisión y su por qué. Buscaste faltantes disfrazados, y si no había, lo dejaste escrito.
5. **Al menos dos decisiones nombran la alternativa que descartaste** y dicen qué se pierde.
6. **Los dos gráficos tienen título y lectura**, y cada uno corresponde a la escala de su variable.
7. **Los archivos de la entrega abren.** El link se ve en una ventana de incógnito, o los adjuntos abren en una máquina que no es la tuya.

7. CÓMO ENTREGAR

La entrega es opcional. Si hiciste el trabajo, mandalo: la devolución es la parte que más enseña.

1. Mandá un correo a **lautarodibartolo@gmail.com** con el asunto, tal cual: T8001 trabajo final - Apellido, Nombre.
2. **Con notebook:** compartí el link de Colab (Compartir → Cualquier persona con el link → Lector) o de un repositorio público, **con las salidas guardadas:** no uses "borrar todas las salidas". Adjuntá el dataset limpio que exporta el notebook.
3. **Con planilla u otra herramienta:** adjuntá el documento con las cinco piezas de la sección 2, el archivo de trabajo, el dataset limpio exportado y el crudo tal como lo bajaste.
4. Si un adjunto pesa más de 25 MB, no lo mandes: alcanza con que tu proceso lo genere.

Y una advertencia de la clase 1 que acá se paga caro: si abrís un CSV de la entrega en Excel para mirarlo, no lo guardes desde ahí. Excel le cambia el separador y el encoding, y el archivo deja de ser el que generó tu proceso.

8. EL EJEMPLO COMPLETO

Antes de empezar, mirá el notebook de la clase 4: es un pipeline entero de punta a punta sobre un caso chico, con las cinco piezas de la sección 2 resueltas en miniatura. No es una plantilla para completar: es el ejemplo de qué forma tiene un trabajo terminado: [04_trabajo_final.ipynb](#).